GL2 · THIẾT KẾ HỆ THỐNG & CÔNG NGHỆ SỬ DỤNG

Thị trường thực tập & part-time tại Việt Nam

Từ tin tuyển dụng thật đến quyết định của sinh viên, nhà trường và doanh nghiệp



Nhóm 3 · Nguyễn Duy Tuấn · Hoàng Thị Thùy Giang · Nguyễn Nam Giang

Phân tích dữ liệu cho Môi trường doanh nghiệp (71DAEE10012) · GV: PGS. TS. Đặng Trần Khánh · Dữ liệu đến 10/11/2026

MỤC LỤC

Nội dung trình bày gồm 5 phần

1	**Tổng quan hệ thống** Yêu cầu hệ thống, giải pháp	Trang 3–4
2	**Kiến trúc hệ thống** 5 tầng, sơ đồ tổng thể, các module code, mô hình dữ liệu, lưu trữ	Trang 5–9
3	**Chi tiết xử lý** Sơ đồ thu thập, làm sạch 7 bước, tỷ giá theo ngày, tin bị sửa/gỡ, dữ liệu thay đổi	Trang 10–16
4	**Công nghệ sử dụng** Công nghệ theo tầng và phiên bản, lý do chọn, sơ đồ web	Trang 17–19
5	**Tổng kết** Đã hoàn thành, phần chưa xong và kế hoạch	Trang 20–21

PHẦN 1 · YÊU CẦU HỆ THỐNG

Hệ thống phải làm được gì?

Chức năng

1. Tự lấy tin thực tập, part-time từ 2 trang mỗi ngày

2. Làm sạch: bỏ trùng, đổi lương ra số, chuẩn hóa nơi làm, ngành

3. Phân tích theo Chương 2–4: thống kê, biểu đồ, kiểm định

4. Nhận ra tin bị sửa hoặc không còn trên trang nguồn

5. Web để xem, lọc, tra cứu, tải CSV

Yêu cầu khác

Đúng quy định: theo robots.txt, nghỉ giữa các lần tải

Chạy lại ra cùng kết quả: tỷ giá theo ngày, không theo lúc chạy

Không mất dữ liệu: giữ nguyên dữ liệu thô, ghi từng dòng

Báo lỗi rõ: trang đổi cấu trúc thì dừng hoặc cảnh báo

Dễ dùng: 1 lệnh hoặc 1 nút là chạy hết

PHẦN 1 · GIẢI PHÁP

Mỗi vấn đề do một phần của hệ thống xử lý

VẤN ĐỀ	GIẢI PHÁP CỦA NHÓM	PHẦN XỬ LÝ
Tin rải rác trên nhiều trang, thay đổi mỗi ngày	Tự thu thập tin mới từ 2 trang mỗi ngày, mỗi ngày một file	`1_crawl.py`
Dữ liệu lộn xộn: tin trùng, lương bằng chữ, ngoại tệ	Làm sạch 7 bước; giữ lương gốc, đổi ngoại tệ theo tỷ giá ngày thu thập	`2_lam_sach.py`
37% tin không ghi lương, khó biết mức hợp lý	Mức lương phổ biến theo ngành; kiểm định so sánh các nhóm	`4_phan_tich.py`
Người dùng không biết code, không mở được CSV	Trang web có bộ lọc, tra cứu, nút lấy dữ liệu mới	`web/app.py`

Cả hệ thống chạy bằng **1 lệnh** python chay.py hoặc **1 nút** trên web.

PHẦN 2 · KIẾN TRÚC HỆ THỐNG · 5 TẦNG

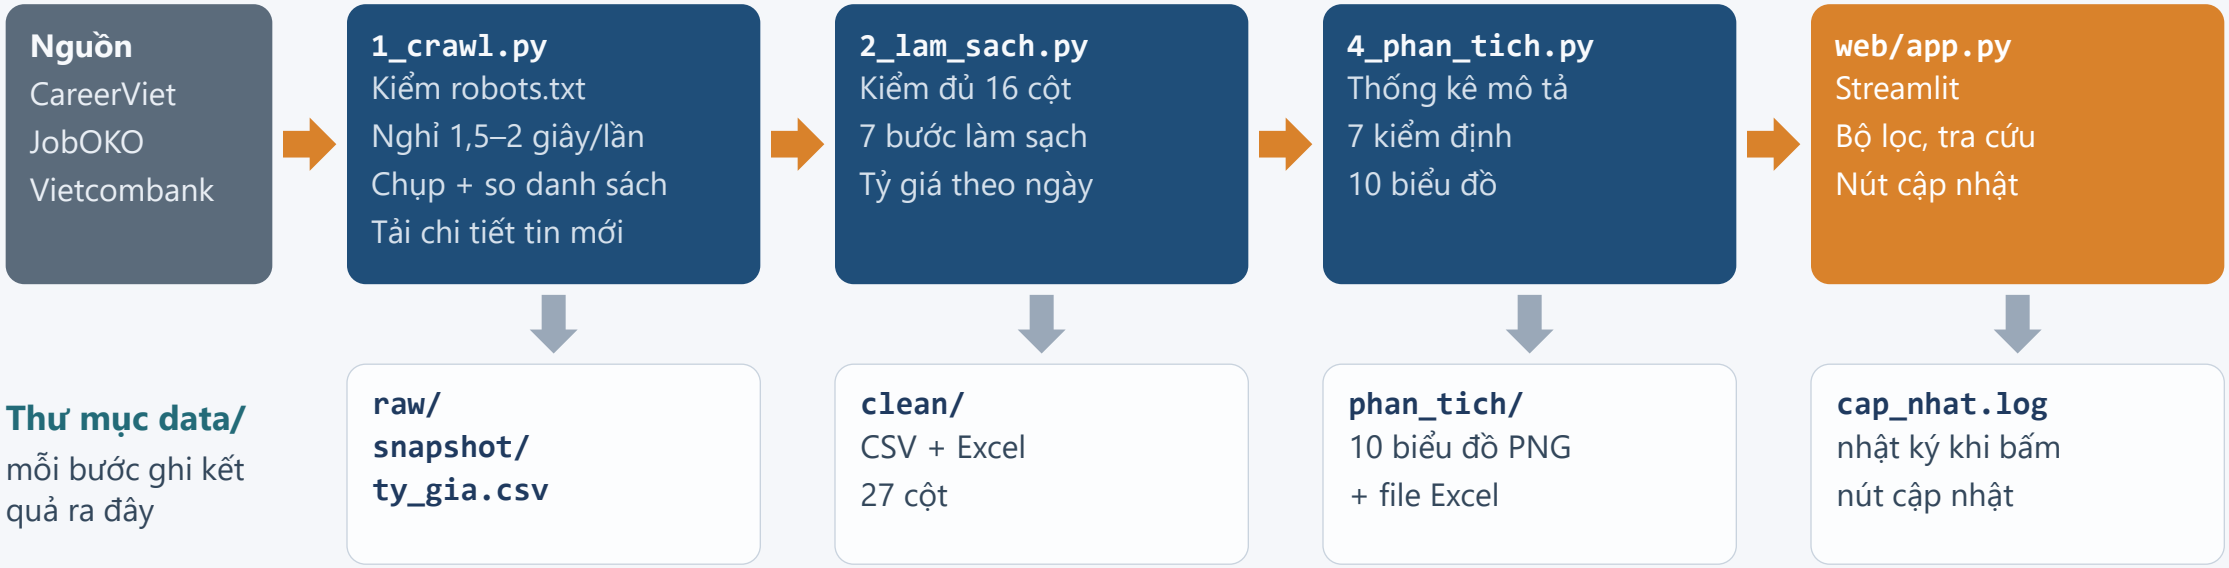
Kiến trúc tổng thể: 5 tầng

1 · Nguồn bên ngoài	**CareerViet** careerviet.vn	**JobOKO** vn.joboko.com	**Vietcombank** tỷ giá theo từng ngày
2 · Thu thập 1_crawl.py, ty_gia.py	**Kiểm robots.txt** nghỉ 1,5–2 giây mỗi lần tải	**Đọc trang danh sách** chụp lại, so với hôm trước	**Tải chi tiết tin mới** đọc JSON-LD; lưu tỷ giá ngày
3 · Lưu trữ thư mục data/	**raw/** dữ liệu thô theo ngày	**snapshot/ · ty_gia.csv** ảnh chụp danh sách, tỷ giá	**clean/ · phan_tich/** dữ liệu sạch, kết quả
4 · Xử lý 2_, 3_, 4_*.py	**Làm sạch** kiểm cột + 7 bước	**Phân tích** thống kê, kiểm định, biểu đồ	**Kiểm chứng** mở lại tin trên trang gốc
5 · Trình bày web/app.py	**Web Streamlit** bộ lọc, tra cứu, tải CSV	**Nút cập nhật** chạy nền chay.py	**Nhật ký** data/cap_nhat.log

Điều phối: python chay.py chạy tầng 2 → 4 theo thứ tự. Mỗi tầng chỉ đọc và ghi file ở tầng lưu trữ, nên lỗi ở đâu chạy lại từ đó. Code để trên GitHub.

PHẦN 2 · KIẾN TRÚC HỆ THỐNG · SƠ ĐỒ TỔNG THỂ

Dữ liệu đi qua những thành phần nào?



`python chay.py` chạy lần lượt 1_crawl → 2_lam_sach → 4_phan_tich; nút trên web gọi lệnh này ở nền. Mỗi bước đọc file của bước trước trong data/, nên lỗi ở đâu chạy lại từ đó. Code để trên GitHub, không đưa data/ lên.

Mỗi file làm gì, đọc gì, ghi gì?

File	Vai trò	Hàm chính	Đọc → Ghi
`1_crawl.py`	Thu thập	`get, *_listing, parse_detail, luu_snapshot, so_sanh_snapshot`	trang web → raw/, snapshot/
`ty_gia.py`	Tỷ giá	`tai_ngay, bo_sung, chon`	Vietcombank → ty_gia.csv
`2_lam_sach.py`	Làm sạch	`parse_salary, to_province, to_contract_type, to_category`	raw/ → clean/
`4_phan_tich.py`	Phân tích	`tai_du_lieu, ve_bieu_do, mo_ta_luong, kiem_dinh`	clean/ → phan_tich/
`3_kiem_chung.py`	Kiểm chứng	mở lại 15 tin ngẫu nhiên, so tên việc + công ty	clean/ → màn hình
`web/app.py`	Web	`tai, khung_cap_nhat, bat_dau_cap_nhat`	clean/ → trình duyệt
`chay.py`	Điều phối	gọi main() của 1 → 2 → 4	không ghi riêng

PHẦN 2 · MÔ HÌNH DỮ LIỆU

Từ 16 cột thô thành 27 cột sạch

Thô · 16 cột

```
source
job_id
title
company
salary_text
location_text
country
employment_type
hinh_thuc
industry
experience
date_posted
deadline
query
url
crawled_at
```

7 bước làm sạch

Nhóm cột	Cột trong file sạch
Tin	`source, job_id, title, company`
Phân loại	`category, contract_type, location, country`
Lương (triệu)	`salary_min, salary_max, salary_mid, salary_unit, salary_label, salary_outlier, salary_text, salary_currency, fx_rate, fx_date, fx_estimated`
Thời gian	`experience_years, date_posted, deadline, con_han`
Mã hóa	`category_code, location_code`
Truy vết	`url, crawl_date`

Khóa mỗi tin: nguồn + mã tin. Trùng thì so tên việc + công ty đã bỏ dấu.

Lúc phân tích thêm 3 cột: khu_vuc, co_luong (0/1), loai_hinh.

PHẦN 2 · LƯU TRỮ

Dữ liệu và code được lưu ở đâu?

`data/raw/careerviet_<ngày>.csv` `data/raw/joboko_<ngày>.csv`	**Dữ liệu thô:** tin mới mỗi ngày, 16 cột, không sửa tay
`data/clean/jobs_clean_<ngày>.csv`	**Dữ liệu sạch:** gộp mọi ngày, 27 cột; phân tích và web đọc file này
`data/clean/jobs_clean_<ngày>.xlsx`	**Bản Excel để người xem:** có bộ lọc và sheet báo cáo 7 bước
`data/phan_tich/<ngày>/`	**Kết quả phân tích:** 10 biểu đồ PNG và file ket_qua_phan_tich.xlsx
`data/cap_nhat.log`	**Nhật ký** mỗi lần bấm nút cập nhật trên web, dùng khi cần xem lỗi
`data/ty_gia.csv` `data/snapshot/`	**Tỷ giá từng ngày**; ảnh chụp danh sách và file tin mới / sửa / không còn
`GitHub · kho riêng tư`	**Code dùng chung cả nhóm;** không đưa data/ và email cá nhân lên

Vì sao dùng file, không dùng cơ sở dữ liệu? Vài nghìn tin thì CSV là đủ, mở bằng Excel kiểm tra được ngay, và mỗi ngày một file nên biết rõ tin nào lấy ngày nào.

PHẦN 3 · SƠ ĐỒ LUỒNG THU THẬP · 1_crawl.py

Một lần thu thập chạy như thế nào?



Làm lần lượt cho CareerViet rồi JobOKO. Ghi từng dòng nên dừng giữa chừng vẫn giữ phần đã tải. Mỗi lần truy cập tự giới thiệu là dự án học thuật.

PHẦN 3 · SƠ ĐỒ LUỒNG LÀM SẠCH · 2_lam_sach.py

Từ file thô đến file sạch qua 7 bước



Nguyên tắc: thiếu thì gắn nhãn, không xóa; chỉ xóa tin trùng hoặc không phải thực tập, part-time.

Báo cáo: số tin vào, ra của từng bước ghi vào sheet bao_cao_7_buoc trong file Excel.

PHẦN 3 · BƯỚC 2 CỦA HỆ THỐNG · 2_lam_sach.py

Làm sạch (1/2): gộp, bỏ trùng, lương, nơi làm

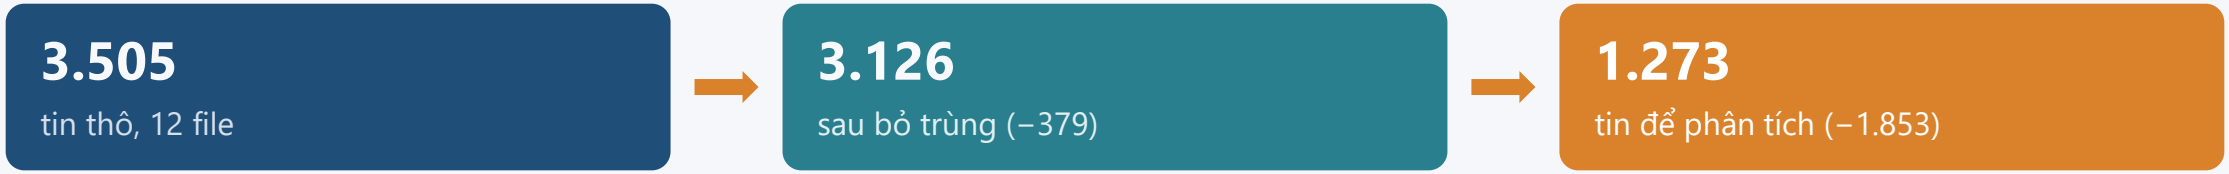
1 · Thu thập 1_crawl.py → **2 · Làm sạch 7 bước nhỏ** → 3 · Phân tích 4_phan_tich.py

#	Bước	Làm như thế nào	Ví dụ / kết quả
1	**Gộp file**	Đọc 12 file thô của 2 trang, kiểm đủ 16 cột rồi nối thành 1 bảng; lấy ngày thu thập từ cột crawled_at	12 file → 3.505 dòng
2	**Bỏ tin trùng**	Cùng trang + cùng mã tin: giữ bản mới nhất. Bỏ dấu tên việc + công ty, cắt đuôi "làm việc tại <tỉnh>", trùng thì giữ 1	"Gia sư Toán Online… tại Cần Thơ / Nghệ An" của RINO EDU → 1 tin. Loại 379
3	**Đổi lương ra số**	Tìm số trong chữ lương, đổi về triệu đồng; ngoại tệ nhân tỷ giá ngày thu thập; không có số thì ghi "Thỏa thuận"; ngoài 0,5–100 triệu thì gắn cờ	"800.000 - 5 triệu" → 0,8 – 5 "Cạnh tranh" → Thỏa thuận
4	**Chuẩn hóa nơi làm**	Tách theo dấu phẩy, bỏ dấu, so với danh sách 63 tỉnh và tên gọi khác (HCM, Sài Gòn…); lấy tỉnh đầu tiên khớp	"Hồ Chí Minh, Hà Nội" → TP. Hồ Chí Minh. 74 cách ghi → 59 tỉnh

PHẦN 3 · BƯỚC 2 CỦA HỆ THỐNG · 2_lam_sach.py

Làm sạch (2/2): quốc gia, loại hình, ngành

#	Bước	Làm như thế nào	Ví dụ / kết quả
5	**Lọc quốc gia**	Tin có tỉnh Việt Nam hoặc không ghi nước thì giữ; ghi Nhật, Hàn, "nước ngoài"... thì loại	Lần này 0 tin bị loại
6	**Lọc loại hình**	Chỉ giữ khi ghi rõ ở 1 trong 3 chỗ: loại hình nhà tuyển dụng chọn (INTERN, PART_TIME), ô "Hình thức", hoặc tiêu đề	"International Sales" khớp nhầm "intern" → loại. Còn 1.273 tin
7	**Gom ngành, mã hóa**	So nhãn ngành của 2 trang với từ khóa của 13 nhóm, ưu tiên nhóm khớp tiêu đề; đổi ngành, tỉnh thành số; tính số năm kinh nghiệm, còn hạn hay không	"Kiểm toán" → Kế toán - Tài chính - Ngân hàng "1 - 2 năm" → 1



Nguyên tắc: thiếu dữ liệu thì gắn nhãn, không xóa; chỉ xóa tin trùng hoặc không phải thực tập, part-time.

PHẦN 3 · THIẾT KẾ · QUY ĐỔI NGOẠI TỆ · ty_gia.py

Tỷ giá nào, của ngày nào?

Trước khi sửa

SAI NGÀY

Lấy tỷ giá 1 lần lúc làm sạch, áp cho mọi tin

Tin lấy ngày 13/10 vẫn đổi theo tỷ giá ngày 10/11

Chạy lại hôm khác: cùng tin ra số khác

Không lưu tỷ giá đã dùng, không kiểm lại được

Đã sửa

ĐÃ CHẠY THỬ

1. Lúc thu thập: lưu tỷ giá ngày đó vào data/ty_gia.csv

2. Mỗi tin đổi theo tỷ giá của ngày thu thập

3. Giữ số gốc: loại tiền, tỷ giá, ngày tỷ giá

4. Ngày cũ: tỷ giá lịch sử thật của Vietcombank

Ngày lấy tin	13/10	03/11	04/11	06/11	09/11	10/11
1 USD, chuyển khoản (đ)	25.720	25.580	25.530	25.400	25.320	25.410
"100 – 150 USD" (triệu)	2,57–3,86	2,56–3,84	2,55–3,83	2,54–3,81	2,53–3,80	2,54–3,81

Chạy thử: làm sạch 2 lần, có mạng và tắt mạng, ra file giống hệt; 7 tin USD đổi lương, các số liệu khác không đổi.

Tin bị sửa hoặc gỡ: hệ thống nhận ra thế nào?

TRƯỚC ĐÂY Tin đã có thì lần sau bỏ qua, nên không biết tin bị đổi lương, đổi tên hay bị gỡ.

Danh sách hôm qua
ảnh chụp lưu mỗi ngày

Danh sách hôm nay
đọc cả tin đã thấy

→

So theo khóa
nguồn + mã tin, như mã số sinh viên; không dùng tên vì tên có thể bị sửa

hash 4 cột: tên việc, công ty, lương, nơi làm

→

MỚI
chỉ có hôm nay

ĐÃ SỬA
có cả 2 ngày, hash khác: ghi cột, giá trị cũ → mới

KHÔNG CÒN TRONG KẾT QUẢ
chỉ có hôm qua; chưa kết luận là đã xóa

Đã code, chạy thử 10/11: bắt đúng tin sửa lương; thêm "(Mới)" hay lương 1 ngày rỗng không bị báo sửa.

Giới hạn: hạn nộp không có trên trang danh sách nên chưa so; tin đăng lại có mã mới coi là tin mới.

PHẦN 3 · THIẾT KẾ · CẤU TRÚC DỮ LIỆU (SCHEMA)

Dữ liệu thay đổi thì hệ thống xử lý ra sao?

Tình huống	Cách xử lý	Trạng thái
2 trang ghi dữ liệu khác nhau	Gom về 16 cột chung; đọc JSON-LD chuẩn schema.org	**Đã làm**
Cần làm sạch lại khi đổi cách xử lý	Giữ nguyên dữ liệu thô, không sửa tay; làm sạch chạy lại từ đầu	**Đã làm**
Tỷ giá đổi theo ngày	Bảng tỷ giá theo ngày thu thập, giữ số gốc (trang 14)	**Đã làm, chạy thử**
Tin bị sửa hoặc gỡ	Ảnh chụp danh sách mỗi ngày, so theo nguồn + mã tin (trang 15)	**Đã làm, chạy thử**
File thô thiếu cột	Đầu bước làm sạch kiểm đủ 16 cột; thiếu thì báo rõ tên file, tên cột và dừng	**Đã làm, chạy thử**
Trang đổi giao diện, không đọc ra tin	Không đọc ra tin nào: cảnh báo, không ghi file rỗng; cột thường có mà rỗng quá nửa: cảnh báo	**Đã làm, thử phần 0 tin**

Nguyên tắc: giữ dữ liệu gốc để luôn làm lại được; báo lỗi rõ thay vì âm thầm ra dữ liệu rỗng hoặc sai.

PHẦN 4 · CÔNG NGHỆ SỬ DỤNG · THEO TẦNG

Mỗi tầng dùng công nghệ gì, bản nào?

Nền tảng	Python 3.14 · VS Code · Git 2.55 + GitHub	mọi file
Thu thập	requests 2.34 · BeautifulSoup 4.15 · JSON-LD	1_crawl.py
Tỷ giá	API tỷ giá theo ngày của Vietcombank	ty_gia.py
Làm sạch	pandas 3.0 · re, unicodedata (có sẵn)	2_lam_sach.py
Lưu trữ	CSV · openpyxl 3.1 (Excel)	thư mục data/
Phân tích	NumPy 2.5 · SciPy 1.18 · matplotlib 3.11 · seaborn 0.13	4_phan_tich.py
Web	Streamlit 1.66 · Altair 6.3 · CSS riêng	web/app.py, style.css

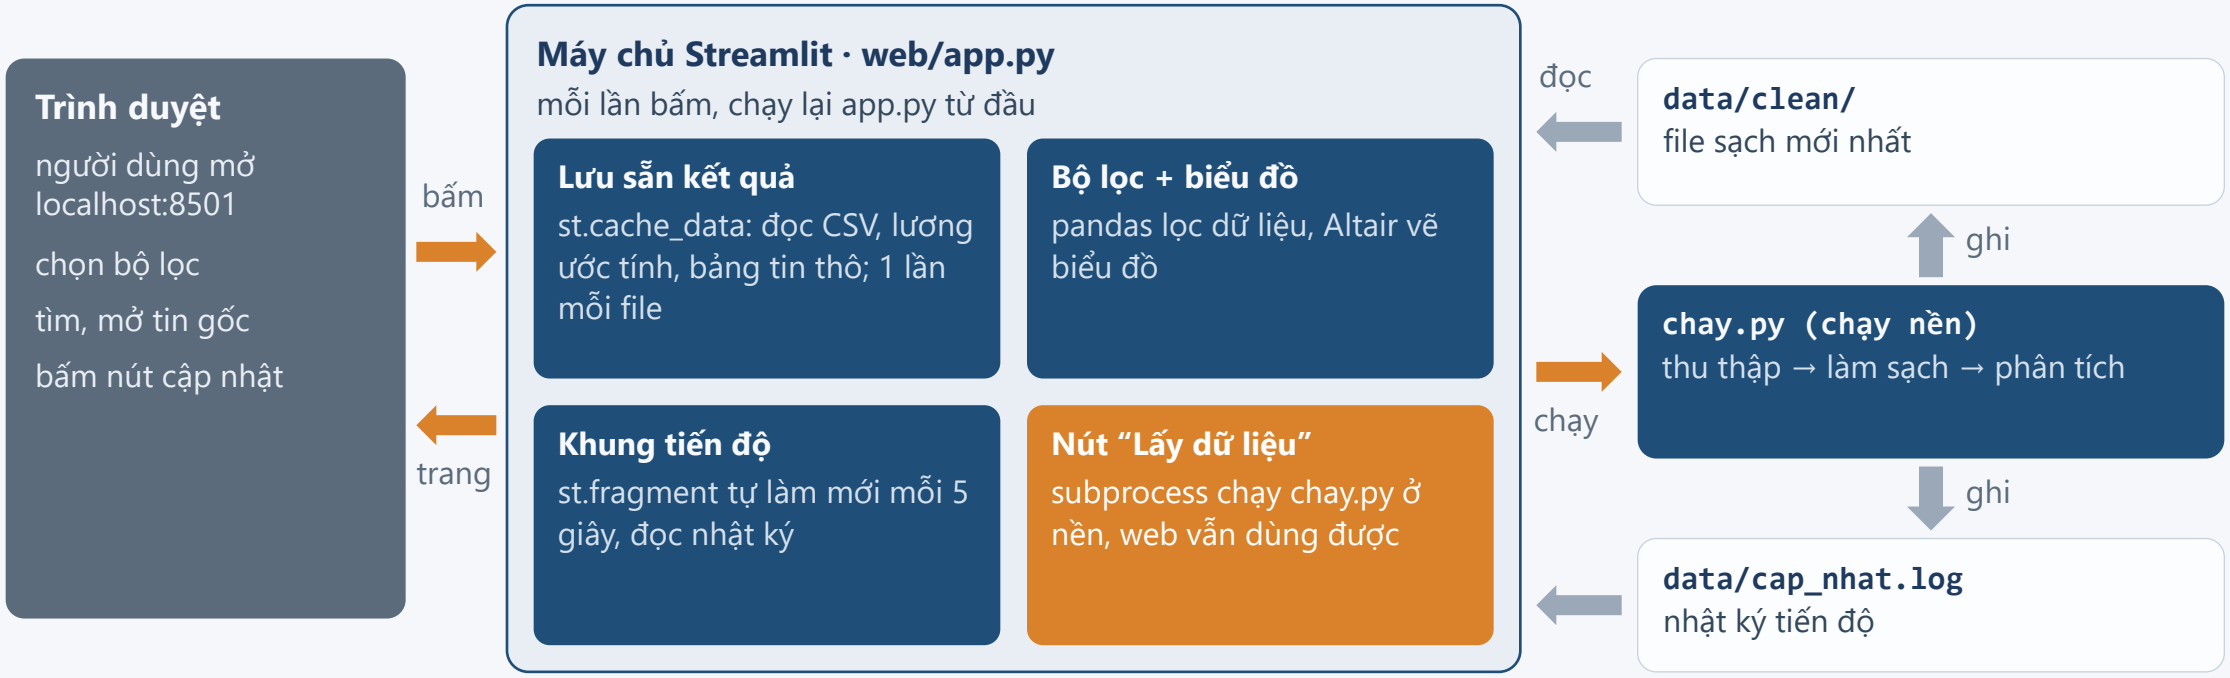
Danh sách thư viện ghi trong requirements.txt, cài 1 lần bằng pip install -r requirements.txt. scikit-learn 1.9 đã cài sẵn cho Chương 5.

Vì sao chọn công nghệ này, không chọn cái khác?

Nhu cầu	Đã chọn	Phương án khác	Vì sao chọn
Tải trang	requests + BeautifulSoup	Selenium, Scrapy	Dữ liệu có sẵn trong HTML, không cần mở trình duyệt; nhẹ, dễ đọc
Đọc tin	JSON-LD (schema.org)	Bóc theo vị trí trên giao diện	Chuẩn chung của 2 trang; trang đổi giao diện ít bị hỏng
Lưu trữ	CSV + Excel	SQLite, MySQL	Vài nghìn tin là đủ; mở Excel kiểm ngay; mỗi ngày 1 file
Tỷ giá	API Vietcombank theo ngày	Số cố định	Đúng ngày thu thập, chạy lại không đổi, kiểm lại được
Xử lý, thống kê	pandas, SciPy	Làm tay trên Excel	Đúng đề cương; tự động, chạy lại được mỗi ngày
Web	Streamlit	Flask + HTML, React	Viết bằng Python, cả nhóm đọc được; không cần máy chủ riêng
Quản lý code	Git + GitHub riêng tư	Gửi file qua tin nhắn	Có lịch sử sửa, cả nhóm dùng chung một bản

PHẦN 4 · SƠ ĐỒ KIẾN TRÚC WEB · web/app.py

Trang web Streamlit hoạt động thế nào?



Đo ngày 10/11, 1.273 tin: mỗi lần bấm bộ lọc từ 3,8 giây còn 0,7 giây nhờ lưu sẵn kết quả.

PHẦN 5 · ĐÃ HOÀN THÀNH

Những phần nhóm đã làm xong

Phần	Đã hoàn thành	Số liệu / bằng chứng
Thu thập	Tự lấy tin 2 trang mỗi ngày, theo robots.txt, bỏ qua tin đã có	12 file, 6 ngày, 3.505 tin thô
Làm sạch	7 bước; đổi lương theo tỷ giá ngày thu thập, giữ số gốc	còn 1.273 tin; chạy 2 lần ra giống hệt
Theo dõi thay đổi	Chụp danh sách mỗi ngày, so tin mới / đã sửa / không còn	chạy thử với trang thật 10/11
Kiểm tra dữ liệu	Kiểm đủ cột, không ghi file rỗng, đối chiếu trang gốc	25/25 tin còn mở khớp
Phân tích	Chương 2–4: thống kê mô tả, 8 loại biểu đồ, 7 kiểm định	10 biểu đồ + file Excel kết quả
Trang web	Bộ lọc, tra cứu, mở tin gốc, tải CSV, nút cập nhật chạy nền	4 tab
Làm việc nhóm	Code trên GitHub riêng tư, chạy cả hệ thống bằng 1 lệnh	python chay.py

PHẦN 5 · CHƯA HOÀN THÀNH & KẾ HOẠCH

Phần chưa xong và kế hoạch tiếp theo

Chưa làm / chưa xong

Máy học (Chương 5): lớp chưa học tới, để dành GL3.

So hạn nộp khi tin bị sửa: trang danh sách không ghi hạn nộp.

Lọc thêm tin chính thức còn lọt (vd “Management Trainee”).

Dữ liệu mới 6 ngày, chưa liên tục: chưa phân tích xu hướng.

Chỉ 2 trang; 65% tin không ghi kinh nghiệm.

Kế hoạch

Từ nay	Thu thập đều mỗi ngày; theo dõi file tin sửa/gỡ
11/11	GL2: thiết kế hệ thống, công nghệ
Chương 5	Thêm mô hình máy học; so cả hạn nộp
09/12	GL3: kiểm tra tiến độ
16/12	Cuối kỳ: thuyết trình, báo cáo kỹ thuật, video

Cảm ơn thầy và các bạn đã lắng nghe!